

PathVQA-TR: Türkçe Dil Destekli Çok Kipli Patoloji Görüntüsü Soru-Cevap Sistemi

Fatih Mehmet Çıldır
Yapay Zeka Mühendisliği Bölümü
Ostim Teknik Üniversitesi
Ankara, Türkiye
Derin Öğrenme Dersi Final Projesi
Danışman: Dr. Murat Şimşek

Abstract—Bu çalışmada, patoloji görüntüleri üzerinde Türkçe doğal dil sorularını yanıtlayabilen çok kipli (multimodal) bir Görsel Soru Cevaplama (Visual Question Answering, VQA) sistemi tasarlanmış ve geliştirilmiştir. PathVQA veri kümesi üzerinde eğitilen sistem; dondurulmuş ve kısmen ince ayar (fine-tuning) uygulanmış Vision Transformer (ViT-B/16) ile BERT kodlayıcılarını, Çok Katmanlı Algılayıcı (MLP) füzyon bloğuyla birleştirmektedir. Türkçe sorular, Helsinki-NLP MarianMT modeli aracılığıyla İngilizceye çevrilerek sisteme dahil edilmektedir. Doğrulama kümesinde elde edilen en iyi doğruluk değeri %86.9 olarak gerçekleşmiştir. Sistem; FastAPI tabanlı bir arka uç ve modern bir web arayüzü aracılığıyla uçtan uca çalışılabilir bir uygulama olarak sunulmaktadır.

Index Terms—Görsel Soru Cevaplama, Patoloji Görüntüleme, Vision Transformer, BERT, Çok Kipli Derin Öğrenme, Türkçe NLP, Fine-Tuning, Transfer Öğrenme

I. GİRİŞ

Tıbbi görüntü analizi, derin öğrenme yöntemlerinin en hızlı ilerleme kaydettiği alanlardan biri olmaya devam etmektedir. Radyoloji, patoloji ve dermatoloji gibi alanlarda Evrişimli Sinir Ağları (CNN) ile elde edilen başarıların ardından, son yıllarda Görsel Soru Cevaplama (VQA) paradigması tıbbi karar destek sistemleri için umut verici bir yol olarak öne çıkmaktadır. VQA sistemleri, bir görüntü ile doğal dil biçiminde ifade edilmiş bir soruyu birlikte işleyerek serbest metin veya sınıf etiketleri şeklinde yanıt üretebilmektedir. Bu sayede klinisyenler ve araştırmacılar, görüntü analizi süreçlerini doğal dil arayüzleri aracılığıyla daha sezgisel bir biçimde gerçekleştirebilmektedir.

PathVQA [1], patoloji görüntüleri ve buna eşlik eden soru-cevap çiftlerinden oluşan referans veri kümelerinden biridir. Veri kümesi 32.799 soru-cevap çiftini ve 4.998 patoloji görüntüsünü kapsamaktadır; soruların yaklaşık %65'i evet/hayır (yes/no) biçiminde kapalı uçlu yapıdadır. Bu çalışmanın odak noktası, söz konusu kapalı uçlu sorulardır; zira bu yapı sınıflandırma problemi olarak modellenebilmekte ve ölçülebilir doğruluk metrikleriyle değerlendirilebilmektedir.

Mevcut PathVQA çalışmalarının tamamına yakını İngilizce giriş varsaymaktadır. TM-PathVQA [2] gibi çalışmalar Almanca ve Fransızca'yı kapsama almış olsa da Türkçe dil desteği

literatürde önemli bir boşluk olarak kalmaktadır. Öte yandan mevcut modellerin büyük çoğunluğu ham sınıflandırma çıktısı üretmekte; bu çıktıları insanın anlayabileceği açıklamalara dönüştürmemektedir.

Bu çalışmada iki temel katkı sunulmaktadır:

- 1) PathVQA için Türkçe dil desteğinin Helsinki-NLP MarianMT çeviri modeli aracılığıyla sağlanması.
- 2) VQA çıktısının mT5-small tabanlı yerel NLP motoru ile kullanıcıya yönelik Türkçe açıklamaya dönüştürülmesi; dış API bağımlılığı bulunmamaktadır.

II. İLGİLİ ÇALIŞMALAR

A. Tıbbi VQA

Med-VQA alanındaki erken çalışmalar CNN ve LSTM mimarilerini birleştirmiştir [3]. Lau ve ark. [4] tıbbi VQA için ilk kapsamlı radyoloji veri kümelerinden birini derlemiştir. He ve ark. [1] patoloji alanına özgü PathVQA veri kümesini tanıtarak CNN tabanlı temel modellerin yes/no sorularında %74.2 doğruluk elde ettiğini raporlamıştır. Nguyen ve ark. [5], dikkat mekanizması ile güçlendirilmiş CNN-LSTM mimarisini kullanmış ve yes/no doğruluğunu %78.3'e taşımıştır. Liu ve ark. [6] ise çok dilli tıbbi VQA veri kümesi SLAKE'i sunmuş; ViT tabanlı modellerin %82.0 doğruluk elde ettiğini göstermiştir.

B. Transformer Tabanlı VQA

ViLBERT [7] ve VisualBERT [8] genel VQA değerlendirmelerinde önemli kazanımlar sağlamıştır. Tıbbi alana uyarlamada LLaVA-Med [10] PathVQA yes/no sorularında %91.0 doğruluğa ulaşmıştır; ancak bu modelin eğitimi onlarca GPU-saat gerektirmektedir. Yan ve ark. [9], ViT kodlayıcısı ile BioMedBERT'i birleştiren hafif bir füzyon mimarisi önermiş ve PathVQA'da %84.7 doğruluk raporlamıştır.

C. Türkçe VQA

Genel amaçlı Türkçe VQA çalışmaları oldukça sınırlıdır. BERTurk [14] ve mBERT [13] tabanlı yaklaşımlar Türkçe metin anlama görevlerinde kullanılmış olmakla birlikte, patoloji görüntüleri üzerinde Türkçe VQA gerçekleştiren herhangi bir çalışmaya rastlanmamıştır.

III. VERİ KÜMESİ

A. PathVQA

PathVQA veri kümesi [1] HuggingFace datasets kütüphanesi aracılığıyla tek satırlık komutla doğrudan yüklenmiştir:

Listing 1. PathVQA Veri Kümesi Yükleme

```
from datasets import load_dataset
ds = load_dataset("flaviaggiannarino/path-vqa")
```

TABLE I
PATHVQA VERİ KÜMESİ İSTATİSTİKLERİ

Bölüm	Toplam Örnek	Yes/No Örnek
Eğitim (Train)	19.654	9.751
Doğrulama (Val)	6.259	3.125
Test	6.719	3.344
Toplam	32.632	16.220

B. Ön İşleme

Yalnızca "yes" veya "no" yanıtı içeren örnekler filtrelenmiş; açık uçlu yanıtlar bu çalışma kapsamı dışında bırakılmıştır. Görüntüler 224×224 piksel boyutuna yeniden ölçeklendirilmiş ve ImageNet istatistikleriyle ($\mu = [0.485, 0.456, 0.406]$, $\sigma = [0.229, 0.224, 0.225]$) normalleştirilmiştir. Sorular BERT tokenizer ile en fazla 128 andaç olacak biçimde kodlanmıştır.

IV. YÖNTEM

A. Mimari Genel Bakış

Önerilen PathVQA-TR mimarisi üç ana bileşenden oluşur: görsel kodlayıcı, metin kodlayıcı ve füzyon modülü. Sistem boru hattı aşağıdaki gibi özetlenebilir:

$$\hat{y} = \text{MLP}([v; t]) \quad (1)$$

Burada $v \in \mathbb{R}^{768}$ görsel öznitelik vektörünü, $t \in \mathbb{R}^{768}$ metin öznitelik vektörünü ve $[:;]$ birleştirme işlemini ifade etmektedir.

B. Görsel Kodlayıcı: ViT-B/16

google/vit-base-patch16-224 ağırlıklarıyla başlatılan Vision Transformer (ViT-B/16) [12], girdi görüntüsünü 16×16 yamaya böler. pooler_output katmanının çıktısı 768 boyutlu görsel gösterim v olarak kullanılmaktadır.

C. Metin Kodlayıcı: BERT

bert-base-uncased ağırlıklarıyla başlatılan BERT [13] modeli metin kodlayıcı olarak kullanılmaktadır. Türkçe sorular, Helsinki-NLP MarianMT modeli (opus-mt-tc-big-tr-en) aracılığıyla önce İngilizceye çevrilmekte ve ardından BERT'e iletilmektedir.

D. MLP Füzyon Modülü

$$f(x) = W_3 \cdot \text{GELU}(W_2 \cdot \text{GELU}(\text{LN}(W_1 x + b_1))) \quad (2)$$

Tam MLP yapısı: $1536 \rightarrow 512 \rightarrow 256 \rightarrow 2$. Her doğrusal katmanın ardından LayerNorm, GELU aktivasyonu ve Dropout ($p = 0.3$) uygulanmaktadır.

E. Temel Model Kodu

Listing 2. PathVQAModel – Füzyon Mimarisi

```
class PathVQAModel(nn.Module):
    def __init__(self, hidden_dim=512,
                  dropout=0.3,
                  finetune_layers=4):
        super().__init__()
        self.vit = ViTModel.from_pretrained(
            "google/vit-base-patch16-224")
        self.bert = BertModel.from_pretrained(
            "bert-base-uncased")
        for p in self.vit.parameters():
            p.requires_grad = False
        for p in self.bert.parameters():
            p.requires_grad = False
        for layer in self.vit.encoder\
            .layer[-finetune_layers:]:
            for p in layer.parameters():
                p.requires_grad = True
        for layer in self.bert.encoder\
            .layer[-finetune_layers:]:
            for p in layer.parameters():
                p.requires_grad = True
        self.fusion = nn.Sequential(
            nn.Linear(768+768, hidden_dim),
            nn.LayerNorm(hidden_dim),
            nn.GELU(), nn.Dropout(dropout),
            nn.Linear(hidden_dim, hidden_dim//2),
            nn.GELU(), nn.Dropout(dropout),
            nn.Linear(hidden_dim//2, 2))
    def forward(self, pixel_values,
                 input_ids, attention_mask):
        v = self.vit(pixel_values=pixel_values)
        .pooler_output
        t = self.bert(input_ids=input_ids,
                      attention_mask=attention_mask)
        .pooler_output
        return self.fusion(
            torch.cat([v, t], dim=-1))
```

F. İnce Ayar Stratejisi

TABLE II
EĞİTİLEBİLİR PARAMETRE DAĞILIMI

Bileşen	Parametre Sayısı
ViT son 4 katman + LayerNorm	≈28M
BERT son 4 katman + Pooler	≈28M
MLP Füzyon	≈1.5M
Toplam	≈57.5M

TABLE III
EĞİTİM DONANIMLARI

Bileşen	Özellik
Geliştirme GPU	NVIDIA RTX 4060 (8 GB VRAM)
Eğitim GPU	Kaggle Tesla T4 x2 (ücretsiz)
Python	3.12
PyTorch	2.x
Transformers	4.40+

V. EĞİTİM SÜRECİ

A. Eğitim Ortamı ve Donanım

B. Hiperparametre Deneyleri

En uygun hiperparametre konfigürasyonuna ulaşmak amacıyla sistematik ablasyon deneyleri yürütülmüştür. Farklı öğrenme hızı, batch boyutu ve dropout değerleriyle gerçekleştirilen deneylerin sonuçları Tablo IV'de özetlenmektedir.

TABLE IV
HIPERPARAMETRE ABLASYON SONUÇLARI

LR	Batch	Dropout	Val Acc
5×10^{-3}	32	0.3	0.714
1×10^{-3}	32	0.3	0.741
1×10^{-4}	64	0.3	0.821
1×10^{-4}	32	0.5	0.834
1×10^{-4}	32	0.1	0.847
1×10^{-4}	32	0.3	0.869
5×10^{-5}	32	0.3	0.861

Yüksek öğrenme hızları (5×10^{-3} ve 1×10^{-3}) ön-eğitilmiş ağırlıkları bozmuş ve doğruluk değerlerinin %74 civarında kalmasına yol açmıştır. Büyük batch boyutu (64) gradient güncellemelerinin daha az sık gerçekleşmesine neden olmuştur. Düşük dropout ($p = 0.1$) eğitim kümesine aşırı uyuma zemin hazırlarken yüksek dropout ($p = 0.5$) model kapasitesini kısıtlamıştır. En iyi konfigürasyon olarak $LR = 1 \times 10^{-4}$, $batch = 32$ ve $dropout = 0.3$ kombinasyonu belirlenmiştir.

TABLE V
NİHAİ EĞİTİM HIPERPARAMETRELERİ

Hiperparametre	Değer
Optimizör	AdamW
Öğrenme Hızı	1×10^{-4}
Ağırlık Azalması	1×10^{-4}
Batch Boyutu	32
Zamanlayıcı	Cosine Annealing
Maksimum Epoch	15
Erken Durdurma	Sabır = 3
Dropout	0.3

C. Epoch Sayısının Belirlenmesi

Maksimum epoch sayısı 15 olarak belirlenmiştir. Bu değer; doğrulama doğruluğunun erken epoch'larda hızla artması ve sonraki epoch'larda yavaşlamasına ilişkin gözlemlerden hareketle seçilmiştir. İlk 5 epoch'ta doğrulama doğruluğu

0.56'dan 0.74'e yükselmekte, ardından artış hızı önemli ölçüde düşmektedir. Bu örüntü, ön-eğitilmiş modellerin ince ayarında yaygın olarak gözlemlenen hızlı yakınsamayla örtüşmektedir [13]. Erken durdurma mekanizması (sabır=3) sistemi gereksiz hesaplama yükünden korumaktadır; bu çalışmada eğitim 14. epoch'ta otomatik olarak durdurulmuştur.

D. Eğitim Süresi

TABLE VI
EĞİTİM SÜRESİ

Aşama	Epoch/Süre	Toplam	Donanım
Freeze (Aşama 1)	≈3.5 dk	≈52 dk	T4 x2
Fine-Tune (Aşama 2)	≈4.2 dk	≈59 dk	T4 x2
Toplam	–	≈111 dk	–

E. Eğitim Dinamikleri

TABLE VII
EĞİTİM AŞAMALARI KARŞILAŞTIRMASI

Aşama	Epoch	Train Acc	Val Acc
Freeze (Aşama 1)	15	0.7504	0.7686
Fine-Tune (Aşama 2)	14	0.9519	0.8691

TABLE VIII
İNCE AYAR EPOCH İLERLEMESİ

Epoch	Train Acc	Val Acc
1	0.5799	0.5664
3	0.6427	0.7238
6	0.7023	0.7437
9	0.9182	0.8605
11	0.9355	0.8650
13	0.9487	0.8691
14	0.9519	0.8634

VI. SİSTEM MİMARISI VE UYGULAMA

A. Inference Pipeline

Listing 3. VQAInference – Predict Metodu

```
def predict(self, image_bytes, question):
    en_q = self.translate_tr_to_en(question)
    image = Image.open(
        io.BytesIO(image_bytes)
    ).convert("RGB")
    pv = self.image_processor(
        images=image,
        return_tensors="pt"
    )["pixel_values"].to(DEVICE)
    enc = self.tokenizer(
        en_q, max_length=128,
        padding="max_length",
        truncation=True,
        return_tensors="pt"
    )
    with torch.no_grad():
        logits = self.model(
            pv,
```

```

enc["input_ids"].to(DEVICE),
enc["attention_mask"].to(DEVICE)
)
probs = torch.softmax(logits, dim=-1)
idx = probs.argmax(1).item()
conf = probs[0][idx].item()
return {"answer": IDX_TO_ANSWER[idx],
        "confidence": round(conf, 4),
        "translated_question": en_q}

```

B. FastAPI Arka Ucu

Sistem, FastAPI çerçevesi üzerine inşa edilmiş bir REST API ile sunulmaktadır. /predict uç noktası çok parçalı form verisi olarak görüntü ve soru kabul etmekte; JSON biçiminde yanıt döndürmektedir.

C. mT5 Tabanlı Açıklama Motoru

Harici API bağımlılığını ortadan kaldırmak amacıyla google/mt5-small modeli Türkçe açıklama üretimi için uyarlanmıştır. Motor; VQA çıktısını, güven düzeyi bandını (yüksek: >0.80, orta: 0.60–0.80, düşük: <0.60) ve kullanıcı sorusunu birleştirerek girdi istemi oluşturmaktadır. Işın araması (beam search, genişlik=4) yöntemiyle en fazla 120 andaç üretilmektedir.

VII. PROJE SÜRECİ VE KARŞILAŞILAN ZORLUKLAR

Oturum Kalıcılığı: Kaggle’ın geçici dosya sistemi nedeniyle eğitilmiş model ağırlıkları birkaç kez kaybolmuştur. Çözüm olarak tüm model kayıt işlemleri /kaggle/working/ dizinine yönlendirilmiş ve commit mekanizması kullanılmıştır.

VRAM Kısıtı: RTX 4060’ın 8 GB VRAM kapasitesi büyük modellerin eğitilmesine olanak tanımamaktadır. Bu nedenle ince ayar katman sayısı 4 ile sınırlandırılmış, eğitim Kaggle T4 altyapısına taşınmıştır.

API Kısıtlaması: Ders gereklilikleri harici API kullanımını yasakladığından yerel mT5-small tabanlı çözüm geliştirilmiştir.

Gerçek Dünya Performansı: Model, PathVQA dışından gelen görüntülerde düşük genelleme kapasitesi sergilemektedir. Bu durum büyük ölçüde eğitim verilerinin homojenliğinden ve dağılım kaymasından (distribution shift) kaynaklanmaktadır.

VIII. SONUÇLAR

TABLE IX
PATHVQA YES/NO DOĞRULUK KARŞILAŞTIRMASI

Model	Val Accuracy
CNN + LSTM [1]	0.742
Attention CNN-LSTM [5]	0.783
ViT + BioMedBERT [9]	0.847
PathVQA-TR Aşama 1 (Freeze)	0.769
PathVQA-TR Aşama 2 (Fine-Tune)	0.869
LLaVA-Med [10]	0.910

Model, temel CNN+LSTM çizgisini belirgin biçimde aşmış ve literatürde benzer hesaplama bütçeli çalışmalarla rekabetçi

bir konuma ulaşmıştır. LLaVA-Med’e kıyasla yaklaşık 4 puanlık fark, onlarca kat daha az hesaplama kaynağı ve harici bağımlılık olmaksızın elde edilmiştir.

PathVQA dışından gelen görüntülerde model performansının belirgin biçimde düştüğü gözlemlenmiştir. Bu durumun başlıca nedenleri: (1) dağılım kayması ve (2) bölge düzeyinde dikkat mekanizması içermeyen tek vektör düzeyindeki füzyon yaklaşımı.

IX. GELECEK ÇALIŞMALAR

Çapraz Dikkat Füzyonu: Cross-attention veya ko-dikkat mekanizmalarına geçiş, görsel ve metin öznitelikleri arasındaki etkileşimleri daha iyi modelleyebilir.

Veri Artırma: Patoloji görüntüleri için renk bozulması ve elastik dönüşüm gibi alana özgü artırma teknikleri genelleme yeteneğini güçlendirebilir.

Uçtan Uca Türkçe Fine-Tuning: BERTurk [14] veya XLM-RoBERTa [15] ile doğrudan Türkçe metin kodlaması, çeviri kaynaklı hata birikimini ortadan kaldırabilir.

Açık Uçlu Sorular: Üretici (generative) bir decoder entegrasyonu sistemin kapsam alanını genişletecektir.

Bölge Düzeyinde Analiz: Grad-CAM görselleştirmelerinin arayüze eklenmesi yorumlanabilirliği arttıracaktır.

Gelişmiş Donanım ile Potansiyel: NVIDIA H200 gibi yüksek bellekli GPU’lara erişim sağlanabilseydi tüm kodlayıcı katmanlarının ince ayarı ve LLaVA-Med ile karşılaştırmalı deneyler gerçekleştirilebilirdi.

X. SONUÇ VE DEĞERLENDİRME

Bu projenin bana çok büyük katkıları oldu özellikle Eğitim hiperparametrelerinin doğruluk metriklerinin üzerindeki etkisini gördüm. Ağırlıkları, Batch boyutunu değiştirmenin gerçek bir projede ne gibi olumlu-olumsuz sonuçlara neden olabileceğini gördüm. Aynı zamanda ilk defa eğitimimi kendi ortamımda değil Kaggle’da gerçekleştirdim. Eğitimde pth’ımı kaydetmekte, ve mT5-small kısmında bazı sorunlar yaşadım ve sorunları çözmek de bana çok şey kattı. ViT ve BERT gibi büyük modellerin çıktılarını vektör seviyesinde birleştirirken mimari olarak nelere dikkat etmem gerektiğini öğrendim. Ders gereksinimleri doğrultusunda, üçüncü parti API’lere bağımlılık oluşturmadan tamamen yerel çalışan mT5-small modelini projeme dahil ettim. Bu deneyim bana, tıp gibi hassas alanlarda (KVKK’da önemli bir nokta olmak üzere) veriyi yerel ortamda neden ve nasıl tutmam gerektiği konusunda çok şey öğretti.

[Bu bölüm yazar tarafından tamamlanacaktır.]

REFERENCES

- [1] X. He, Y. Zhang, L. Mou, E. Xing, ve P. Xie, “PathVQA: 30000+ Questions for Medical Visual Question Answering,” *arXiv preprint arXiv:2003.10286*, 2020.
- [2] F. Giammarino, “TM-PathVQA: Trilingual Medical PathVQA Dataset,” HuggingFace Datasets, 2023.
- [3] S. Antol ve ark., “VQA: Visual Question Answering,” *Proc. IEEE ICCV*, 2015, ss. 2425–2433.
- [4] J. J. Lau ve ark., “A Dataset of Clinically Generated Visual Questions and Answers about Radiology Images,” *Scientific Data*, c. 5, s. 180251, 2018.
- [5] B. D. Nguyen ve ark., “Overcoming Data Limitation in Medical Visual Question Answering,” *Proc. MICCAI*, 2019, ss. 522–530.

- [6] B. Liu ve ark., “SLAKE: A Semantically-Labeled Knowledge-Enhanced Dataset for Medical Visual Question Answering,” *Proc. IEEE ISBI*, 2021.
- [7] J. Lu, D. Batra, D. Parikh, ve S. Lee, “ViLBERT: Pretraining Task-Agnostic Visiolinguistic Representations,” *Advances in NeurIPS*, 2019.
- [8] L. H. Li, M. Yatskar, D. Yin, C.-J. Hsieh, ve K.-W. Chang, “VisualBERT: A Simple and Performant Baseline for Vision and Language,” *arXiv preprint arXiv:1908.03557*, 2019.
- [9] Z. Yan ve ark., “Multimodal Medical Visual Question Answering via Conditional Alignment,” *arXiv preprint arXiv:2306.05915*, 2023.
- [10] C. Li ve ark., “LLaVA-Med: Training a Large Language-and-Vision Assistant for Biomedicine in One Day,” *Advances in NeurIPS*, 2023.
- [11] S. Bannur ve ark., “Learning to Exploit Temporal Structure for Biomedical Vision-Language Processing,” *Proc. IEEE CVPR*, 2023.
- [12] A. Dosovitskiy ve ark., “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale,” *arXiv preprint arXiv:2010.11929*, 2020.
- [13] J. Devlin, M.-W. Chang, K. Lee, ve K. Toutanova, “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,” *Proc. NAACL-HLT*, 2019, ss. 4171–4186.
- [14] S. Schweter, “BERTurk — BERT Models for Turkish,” *Zenodo*, 2020.
- [15] A. Conneau ve ark., “Unsupervised Cross-lingual Representation Learning at Scale,” *Proc. ACL*, 2020, ss. 8440–8451.